



Univerzitet u Sarajevu  
Elektrotehnički fakultet u Sarajevu  
Odsjek za računarstvo i informatiku



# **Interfejs mozak-računar (BCI) sa primjenom EEG tehnologije**

Digitalno procesiranje signala  
SEMINARSKI RAD

Studentice:  
Zerina Ahmetović, 19043  
Lamija Gutić, 18977

Mentorica:  
vanr. prof. dr Amila Akagić

Sarajevo, april 2024.

# SADRŽAJ

0. Abstrakt.....	2
1. Uvod.....	3
2. Pregled BCI.....	4
2.1. Tipovi BCI-a.....	4
2.2. Princip rada BCI-a sa EEG-om.....	5
2.3. Svrha BCI-a.....	6
3. Osnove EEG tehnologije.....	6
3.1. Klasifikacija EEG signala/moždanih talasa.....	8
4. Predprocesiranje EEG signala.....	10
4.1. EEG artefakti.....	10
4.2. Metode uklanjanja artefakata.....	11
4.2.1 Filteri za procesiranje EEG signala.....	11
4.2.2 Slijepo uklanjanje izvora(BSS).....	14
5. Ekstrakcija značajki i analiza signala.....	15
5.1. Analiza signala.....	15
5.2. Ekstrakcija značajki.....	16
5.2.1 FFT.....	16
5.2.2 Hjortovi parametri.....	17
5.2.3 Metoda ekstrakcije snage pojasa.....	17
5.2.4 Wavelet transformacija.....	17
6. Klasifikacija i algoritmi mašinskog učenja.....	20
7. Primjena BCI sistema.....	21
7.1. BCI u zabavne svrhe.....	22
7.2. Izazovi u daljem razvoju BCI.....	23
8. Zaključak i diskusija.....	24
9. Reference.....	25

## **ABSTRAKT**

Ovaj seminarski rad obrađuje rad interfejsa mozak-računar (engl. brain-computer interface – BCI) sa naglaskom na primjenu elektroencefalografije u prikupljanju i obradi signala potrebnih za rad BCI sistema. BCI predstavlja inovativno tehnološko dostignuće u pogledu interakcije čovjek-računar jer omogućava direktnu komunikaciju ljudskog mozga i nekog eksternog uređaja što za rezultat ima mnoge primjene. Ovaj rad daje pregled BCI sistema, osnove EEG tehnologije, te posebno istražuje procesiranje EEG signala u pogledu njihovog korištenja za rad BCI sistema. U ovom radu detaljno se obrađuju metode za uklanjanje šumova prisutnih kod EEG signala, ekstrakcija značajki (engl. feature extraction) i analiza signala kao nezamjenjiv dio dizajna BCI sistema, te se posebno predstavljaju metode za ekstrakciju značajki poput wavelet transformacije (WT) i Fast Fourier Transform (FFT). Pored toga, predstavljena je primjena BCI sistema u različitim područjima, uključujući medicinu gdje se ova tehnologija koristi za rehabilitaciju i dijagnostiku pacijenata sa neurološkim oboljenja. Uzimajući u obzir potencijal koji BCI sistemi nude u pogledu poboljšanja kvaliteta života ljudi, ova tehnologija predstavlja veliki iskorak u pogledu ljudske interakcije sa računarom.

# 1. UVOD

Ljudski mozak oduvijek je bio predmet istraživanja unutar mnogih naučnih disciplina, što je podrazumijevalo i rad na tehnologijama koje za cilj imaju bolje razumijevanje rada moždanih signala, čije je dobro poznavanje izuzetno važno u neuronauci i medicini. U medicini se ove tehnologije koriste za dijagnostiku i pretrage moždanih oboljenja, dok se u neuronauci koriste za posmatranje raznih pojava vezanih za ljudski mozak.

Jedan od rezultata ovih istraživanja prvo je bila elektroencefalografija (EEG), tehnologija nastala 1930-ih koja se i danas koristi za istraživanje električne aktivnosti mozga. Koristeći EEG, istraživači su konačno mogli da moždanu aktivnost kod ljudi pretvore u nešto mjerljivo, što je bilo od velike važnosti za razvoj naučnih i tehnoloških disciplina poput neuronauke, ali i tehnoloških disciplina u kojim su istraživači već sredinom i krajem prošlog stoljeća počeli razmatrati kako je moguće unaprijediti komunikaciju čovjeka i računara.

Ideja da bi se ovi signali mogli koristiti za komunikaciju i kontrolu prisutna je već nekoliko decenija, ali se tek u posljednjih 25 godina radi na istraživanjima koja ispituju sve mogućnosti u pogledu komunikacije mozga sa računarom [25]. Kao rezultat ovog istraživanja, došlo se do nove tehnologije: interfejs mozak-računar (engl. brain-computer interface - BCI). Prvi koji je došao do ovog termina je profesor Jacques Vidal sa Univerziteta u Kaliforniji 1973. godine [26]. Razvojem računara, BCI je također poprimio jednu novu dimenziju i iako je poprilično nov, BCI ima potencijal da promijeni način na koji ljudi komuniciraju sa računarima i drugim uređajima [9].

U pitanju je sistem koji prikuplja ljudske neuralne odzive i uključuje procesiranje prikupljenih moždanih signala kako bi se ti odgovori pretvorili u komande i upravljačke radnje [27]. U suštini, BCI je sistem koji prevodi moždane signale u druge vrste izlaza [25]. Prema [25], postoji nekoliko razloga zašto je BCI u posljednjoj deceniji postao predmet istraživanja u okviru kompjuterskih nauka: prvi je pojava moćnog i dosta jeftinijeg kompjuterskog hardvera i softvera koji omogućava veliku brzinu za analizu moždanih aktivnosti, što je ključno za nešto što se dešava u realnom vremenu poput BCI-ja. Iako je BCI dugo postojao kao ideja i kao nešto što bi potencijalno moglo da zaživi, bilo je potrebno ispuniti uslove u drugim sferama kako bi se ovo istraživanje moglo nastaviti. Drugi faktor je bolje poznavanje centralnog nervnog sistema koje je rezultat istraživanja posljednjih 50 godina, a treći faktor je prepoznavanje potreba ljudi sa neurološkim oboljenjima poput cerebralne paralize, povreda kičmene moždine, moždanih udara, multiple skleroze i slično. Iz svega ovoga, možemo vidjeti da je obrada signala za BCI ključna te ćemo se stoga u ovom radu velikim dijelom baviti procesiranjem moždanih signala koje prikuplja EEG a koji se koriste u BCI sistemima.

Ovaj rad opisuje osnove rada EEG tehnologije koja je ključna u radu BCI sistema, pregled i način rada BCI-ja, matematičke modele koji se koriste za obradu signala koje prikuplja EEG, obradu EEG signala u pogledu BCI sistema, što uključuje njihovo predprocesiranje, izdvajanje karakteristika (feature extraction), analizu signala, te njihovu klasifikaciju. Pored toga, dio rada obrađuje i primjenu BCI sistema te potencijalne buduće korake u razvoju ove rastuće tehnologije.

## 2. PREGLED BCI SISTEMA

Interfejs mozak-računar (engl. brain-computer interface - BCI) je *hardverski i softverski komunikacioni sistem koji omogućava upravljanje vanjskim uređajima (najčešće računarima) samo pomoću cerebralne aktivnosti, korištenjem signala generisanim preko EEG (elektroencefalografske) aktivnosti.*

Ovaj model predstavlja vid vještačke inteligencije koja može prepoznati šablone (engl. patterns) u moždanim signalima, prateći pet etapa:

- akvizicija signala,
- predprocesiranje ili poboljšanje signala,
- ekstrakcija značajki (engl. features – *feature extraction*),
- klasifikacija,
- interfejs za upravljanje. [1]

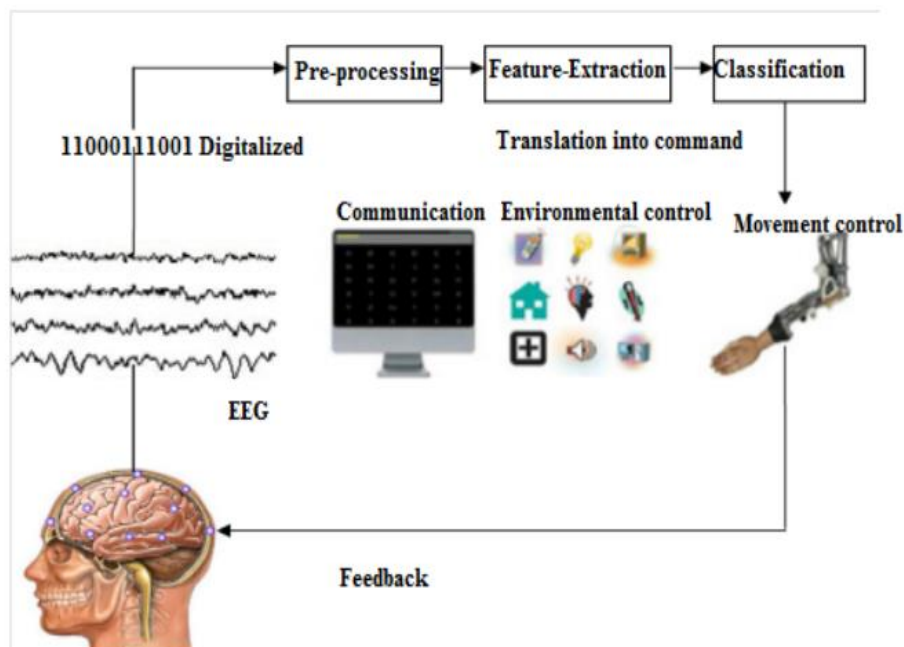


Figura 1: Model BCI sistema

### 2.1 Tipovi BCI-a

Razlikujemo tri tipa BCI-ja: **invazivni**, **neinvazivni** i **parcijalno invazivni**. U ovom radu će fokus biti isključivo na neinvazivnom, koji se često naziva i samo EEG. [3]

Neinvazivni BCI sistemi koriste elektroencefalografsku (EEG) aktivnost snimljenu na vlasištu ili aktivnost jedne jedinice snimljenu unutar korteksa kako bi upravljali kretanjem kursora, odabirali slova ili ikone ili upravljali neuroprotezom. [2]



Source: GAO analysis (data). koya979/stock.adobe.com (images). | GAO-22-106118

Note: Connections between brain and device may be wired or wireless.

Figura 2: *Primjeri implantiranih (lijevo) i nosivih (desno) BCI sistema*

## 2.2 Princip rada BCI-a sa EEG-om

BCI sistemi zasnovani na elektroencefalografiji sastoje se od skupa senzora koji prikupljaju signale elektroencefalografije s različitih područja mozga. Međutim, na kvalitetu signala elektroencefalografije utječe tjeme, lubanja i mnogi drugi slojevi, kao i pozadinska buka [1].

Uspješno funkcioniranje BCI-a u velikoj mjeri zavisi od pravilne kontrole EEG aktivnosti. Kao i svaki komunikacijski i kontrolni sistem, BCI ima **ulaz, izlaz i algoritam za prevođenje**. Centralni element u svakom BCI-u jeste upravo taj algoritam za prevođenje koji pretvara elektrofiziološki ulaz korisnika u izlaz koji upravlja vanjskim uređajima. Ulaz u BCI sastoji se od određene značajke (ili značajki) moždane aktivnosti i metodologije korištene za mjerenje te značajke [2].

Svaki BCI koristi određeni algoritam za prevođenje svog ulaza (npr. odabrane EEG značajke) u izlazne kontrolne signale. Taj algoritam može uključivati linearne ili nelinearne jednačine ili druge metode te može uključivati kontinuirano prilagođavanje važnih parametara ključnim aspektima ulaza koje pruža korisnik.

Izlazi BCI-ja mogu biti kretanje kursora, odabir slova ili ikona ili neka druga forma upravljanja uređajem, te pružaju povratne informacije koje korisnik i BCI mogu koristiti za prilagodbu kako bi optimizirali komunikaciju.

Osim svog ulaza, algoritma za prevođenje i izlaza, svaki BCI ima i druge karakteristike - mehanizam za uključivanje/isključivanje (npr. EEG signale ili konvencionalnu kontrolu); vrijeme odziva, brzinu i tačnost te njihovu kombinaciju u stopu prijenosa informacija; vrstu i opseg potrebne obuke korisnika, odgovarajuću korisničku populaciju te odgovarajuće primjene.

Neki protokoli BCI-ja traže od korisnika da koriste vrlo specifičnu motoričku imaginaciju (npr. imaginacija kretanja desne ili lijeve ruke) ili druge mentalne zadatke kako bi

proizveli EEG značajke koje sistem koristi kao kontrolne signale (npr. [7, 9]). Drugi mogu ostaviti izbor imaginacije ili odluku o korištenju bilo kakve imaginacije [2].

## 2.3 Svrha BCI-a

Trenutni BCI sistemi imaju maksimalne stope prijenosa informacija od 5–25 b/min. Postizanje veće brzine i tačnosti zavisi od poboljšanja u obradi signala, algoritmima za prevođenje i obuci korisnika [2].

Osnovni cilj istraživanja ove tehnologije jeste pružiti mogućnost komunikacije onespособljenim osobama, kako paraliziranim, tako i osobama sa raznim neurološkim poremećajima [1].

Glavni razlog nedavnog interesa za razvoj BCI-ja - mogućnosti koje pruža, u vidu nove tehnologije za augmentativnu komunikaciju onima koji su paralizirani ili imaju druge teške pokretne poteškoće. Sve druge tehnologije za augmentativnu komunikaciju zahtijevaju neki oblik kontrole mišića i stoga možda nisu korisne za one s najtežim motoričkim oštećenjima [2].



Figura 3: *Primjeri primjene BCI sistema uključuju aplikaciju za spelovanje, interfejs za pametni telefon, dron kojim upravlja BCI, i robotsku ruku*

## 3. OSNOVE EEG TEHNOLOGIJE

Savremena medicinska dijagnostika zahtijeva veliki broj tehnologija za snimanje. Kako je medicina napredovala, tako se dolazilo do sve boljih metoda za snimanje i posmatranje ljudskog organizma. Jedna od takvih najstarijih i najviše korištenih metoda je i **elektroencefalografija (EEG)**. Elektroencefalografija je tehnologija koja se koristi za istraživanje električne aktivnosti mozga [6] i danas se smatra jednom od najvažnijih dijagnostičkih tehnika koje se koriste za ustanovljivanje neuroloških oboljenja, poput epilepsije, povreda glave i slično. Prvi EEG snimač je svijetu predstavio Hans Berger 1929.

godine, a naziv **elektroencefalogram** je koristio da opiše grafičku reprezentaciju električnih struja koje se stvaraju u mozgu [8].

**Elektroencefalogram vlasišta** se definira kao *električna aktivnost promjenljive prirode snimljena sa površine vlasišta nakon što je očitaju metalne elektrode i drugi provodni mediji* [7]. Tokom EEG testa, na površinu vlasišta se postave mali diskovi (elektrode), od kojih je svaki povezan sa pojačivačem (jedan pojačivač po paru elektroda) i EEG snimač [8]. Električni signali iz mozga se pretvaraju u valovite linije na ekranu koje predstavljaju rezultat mjerenja. Elektrode detektuju veoma male električne naboje koji su rezultat aktivnosti moždanih ćelija. Budući da lobanja priguši signale koje EEG snimač treba da očita, mjereni električni potencijali imaju amplitude u rasponu od samo 10  $\mu V$  do 100  $\mu V$  [10]. Iz ovog razloga potrebno je koristiti pojačivač koji će pomoći u očitavanju i zapisivanju ovih signala. Koristeći pojačivač, ti signali se pojačavaju i predstavljaju grafički na računaru, ili na papiru [8].

Budući da u ljudskom mozgu postoji oko 86 milijardi neurona, EEG bilježi sumaciju električne aktivnosti velike grupe neurona sa sličnom (ili susjednom) lokacijom [10]. Matematički govoreći, vrijednost potencijala koje registruju susjedne elektrode se može predstaviti jednačinom:

$$V_n = V_{EEGn} + V_{CMS}$$

Gdje je  $V_n$  - vrijednost potencijala na elektrodama,  $V_{EEGn}$  - potencijal povezan sa električnom aktivnosti mozga.  $V_{CMS}$  - zajednički signal na svim elektrodama, također povezan sa interferencijom iz mreže [9].




Figura 4: Skica korištenja elektroencefalograma [10]

Postoje dvije vrste EEG-a, zavisno od toga odakle iz glave se signal uzima: sa vlasišta ili intrakranijalni [8]. EEG gdje se signali uzimaju sa površine vlasišta je uglavnom već opisan i u pitanju je neinvazivna metoda gdje se elektrode postave u svrhu mjerenja električnih aktivnosti u mozgu. Kada je ovaj EEG u pitanju, vrlo je važan dobar mehanički i električni kontakt kako bi se ostvarilo ispravno mjerenje. Kada je u pitanju intrakranijalni EEG, posebne elektrode se tokom operacije postave u mozak [8]. Ovo mjerenje se uglavnom



koristi kada su u pitanju pacijenti koji boluju od epilepsije, pogotovo u slučaju kada uobičajene metode ne rješavaju napade [11].

Pitanje postavljanja elektrodi je važno jer su različiti režnji moždanog korteksa odgovorni za procesiranje različitih tipova aktivnosti [8]. Standardna metoda za lokalizaciju elektrodi na vlasištu je internacionalni 10-20 sistem elektroda. 10 i 20 predstavljaju susjedne elektrode koje su ili 10 ili 20% ukupne udaljenosti naprijed nazad ili lijevo-desno od lobanje. Pozicije su određene sa dvije tačke: nasion - tačka između čela i nosa, u nivou očiju, i inon koja je koštana izbočina u dnu lobanje na sredini pozadine glave [8]. Slika ispod predstavlja raspodjelu elektroda za EEG.

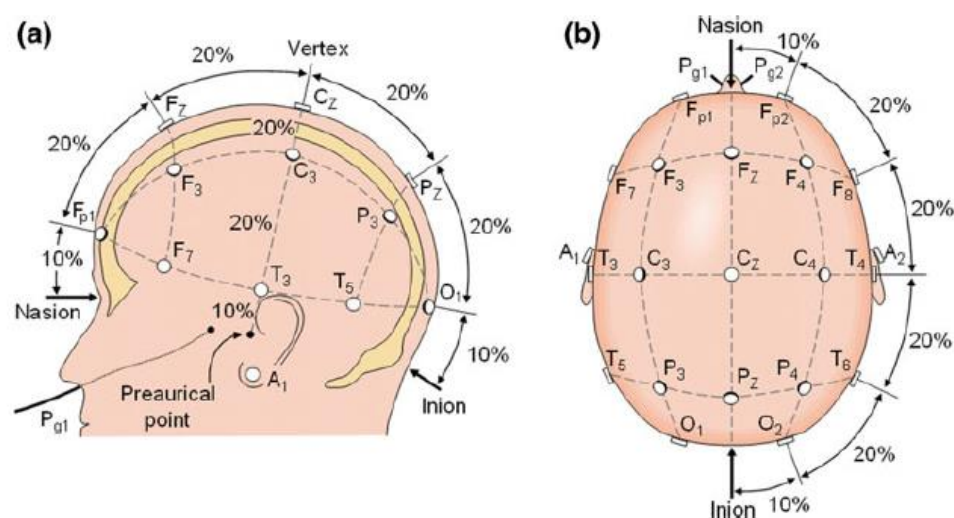


Figura 5: Međunarodni "10-20" sistem raspodjele elektroda [8]

### 3.1 Klasifikacija EEG signala/moždanih talasa

EEG signali se dijele po frekvencijama. Njihova frekvencija i potencijal variraju od 1 do 50 Hz i 10-100  $\mu$ V kada se mjere na površini vlasišta [14].

#### *Delta ( $\delta$ ) talasi (0.1-4 Hz)*

**Delta talasi** se vežu za duboke nivoe opuštanja i sna. Oni su najsporiji zabilježeni moždani talasi kod ljudi i viši nivoi se često nalaze kod mlađe djece. Tokom procesa starenja, niže vrijednosti delta talasa se proizvode [14]. Neka istraživanja sugerišu da se delta talasi vezani za mnoge od naših nesvjesnih tjelesnih funkcija, poput regulacije kardiovaskularnog i digestivnog sistema. Također, jedna od karakteristika ovih talasa je da se ne prikazuju u normalnom EEG snimku budne odrasle osobe [9].

#### *Theta ( $\theta$ ) talasi (4-8 Hz)*

**Theta talasi** su talasi koji su najčešće prisutni u hipnotičkom stanju ili stanju potpune meditacije [14, 21]. U ovom stanju, moždani theta talasi su optimalni i osoba je podložnija hipnozi i povezanim terapijama. Također se veže i za poboljšanje kreativnosti i intuicije [14].

Ovi talasi su normalni za djecu ispod 13 godina.

#### *Alfa ( $\alpha$ ) talasi (8-12 Hz)*

**Alfa talase** neki autori navode kao “frekvencijski most” između našeg svjesnog razmišljanja (beta) i podsvijesti (theta) [14]. Moguće ih je pronaći kod svih uzrasta, ali najčešće kod odraslih koji su budni ali zatvorenih očiju. Pojavljuje se na obje strane glave ali neznatno veća amplituda je zabilježena u nedominantnoj strani mozga, te predstavlja bijelu masu mozga [21].

#### *Beta ( $\beta$ ) talasi (12-30 Hz)*

**Beta talasi** su poznati kao visokofrekvencijski talasi i vežu se za stanje budnosti kod ljudi, te se najčešće se pojavljuju tokom svjesnog stanja i kognitivnih aktivnosti, popu računanja, čitanja, govora i razmišljanja [14]. Visoki nivoi beta talasa imaju stimulirajući efekt, što objašnjava pojavu tzv. alfa blokiranja koja nastaje kada mozak ograničava pojavu alfa talasa ako se pojave visoki nivoi beta aktivnosti [14, 21]. Povišen nivo ovih talasa može uzrokovati stres i anksioznost [14].

#### *Gama ( $\gamma$ ) talasi ( $>30$ Hz)*

**Gama talasi** se vežu za učenje, pamćenje i procesiranje te se navode kao veza koju naša čula koriste da procesiraju nove informacije. Niski nivoi ovih talasa se vežu za depresiju i probleme s učenjem, dok se visoki nivoi vežu za anksioznost i stres [14].






Vrsta	Frekvencija (Hz)	Izgled signala
Delta	0.1-4	
Theta	4-8	
Alfa	8-12	
Beta	12-30	
Gamma	Iznad 30	

Tabela 1: Klasifikacija EEG signala

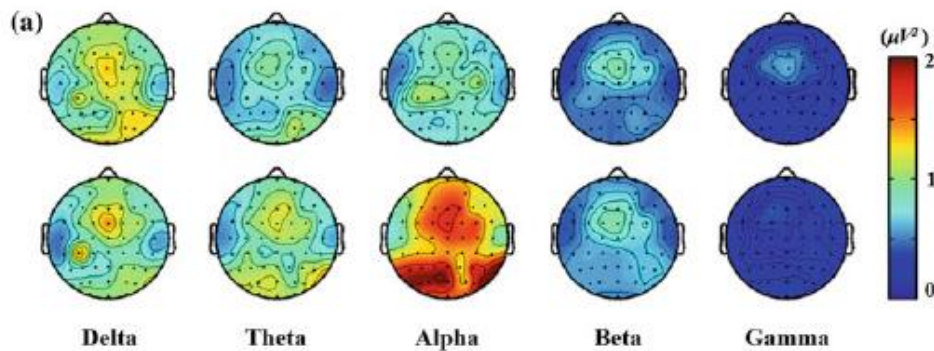


Figura 6: *Primjeri topografija koje prikazuju prostorne distribucije prosječnih apsolutnih spektralnih stepena za pet frekvencionih okvira: delta (1-5 Hz), theta (5-8 Hz), alfa (8-12 Hz), beta (15-30 Hz) i gama (30-55 Hz) [16]*

## 4. PREDPROCESIRANJE EEG SIGNALA

Procesiranje EEG signala zahtijeva pažljivu analizu signala i razlikuje se u zavisnosti od aplikacije ili vrste informacija potrebnih za njihovu interpretaciju [14]. Budući da se zabilježeni EEG signal ne može koristiti direktno u fazi procesiranja, potrebno je da ovi signali budu filtrirani u fazi **predprocesiranja** BCI sistema (pogledati figuru 1). Ovo je nezamjenljiv korak u analizi EEG-a u većini okolnosti [16]. Također, predprocesiranje često uključuje i procedure kojima se pojačavaju prostorno-vremenske karakteristike EEG signala vezane za zadatak u studiji [16].

### 4.1 EEG artefakti

**EEG artefakti** snimljenih signala su svi signali koji kontaminiraju moždane signale tokom procesa njihove akvizicije [15]. Postoje dvije vrste takvih 'ometača': ekstrasfiziološki (vanjski) i fiziološki (interni) artefakti [15,16]. Vanjski artefakti nastaju uslijed vanjskih okolnosti, za razliku od internih artefakata koji nastaju uslijed rada ljudskog organizma tokom prikupljanja moždanih signala, ali iz izvora koji nisu mozak, poput treptaja oka, pokreta očne jabučice, disanja, otkucaja srca, kontrakcije mišića i slično [15].

Kada su u pitanju vanjski faktori koji ometaju prikupljanje moždanih signala, to su najčešće bežični telekomunikacijski signali, položaj elektrode (da li je elektroda dovoljno dobro pričvršćena uz glavu), oprema za snimanje i pokreti kablova [16]. Budući da se radi o vanjskim faktorima, ova ometanja je mnogo lakše spriječiti nego ono što se dešava u ljudskom organizmu tokom EEG snimanja. Iz ovog razloga, najveći broj metoda za uklanjanje se veže za interne artefakte [16].

**Okularni (očni) artefakti** su električne aktivnosti koje nastaju pokretom oka ili treptajem. Njihova interferencija je dovoljno vidljiva na EEG snimcima, posebno u frontalnim i okcipitalnim EEG snimcima [23]. Ove artefakte moguće je detektovati koristeći elektrookulogram (EOG) [16]. EOG se koristi za bilježenje pokreta oka tokom EEG snimanja. Ovo snimanje se zasniva na rožnično-retinalnom potencijalu (razlika električnog naboja između rožnice i retine), sa dugom očnom osom koja djeluje kao dipol [14]. Kako bi se zabilježili pokreti oka, parovi elektroda (pravljenih od srebro-hlorida) se postave ispod i iznad očiju, ili lijevo i desno od oka [14]. Ako se oko kreće od centra ka

jednoj od elektroda, ova elektroda “vidi” pozitivnu stranu retine, dok suprotna elektroda “vidi” negativnu stranu retina”. Ovo uzrokuje razliku potencijala između elektroda, čime je moguće zabilježiti pokret oka [14]. Glavna tri artefakta koja EOG analizira su treptaj, sakada i fiksacija. Treptaji se smatraju kao šum za moždane signale, i njihovo filtriranje može poboljšati podatke koji se analiziraju, dok su sakade promjene napona kada oko nasumično prelazi s jedne fiksacije na drugu [14].

**Mišićni artefakti** uključuju električne aktivnosti koje nastaju mišićnim kontrakcijama dijelova tijela, poput glave, lica i udova [14]. Ovi artefakti su dosta raznolikiji od mišićnih, i zavise od toga o kojim se mišićima radi i kakve pokrete prave. Signale koji su povezani sa mišićima mjeri se elektromiogramom (EMG). Zbog svoje rasprostranjenosti u mozgu, artefakte koje stvaraju mišići je posebno teško ukloniti [14].

**Srčani artefakti** nastaju uslijed rada srca i najčešće pokazuju vrlo niske amplitude u poređenju sa drugim. Njihov utjecaj mjeri se elektrokardiogramom (EKG) [14]. Zbog regularnosti ritma srca, ove artefakte je lakše ukloniti i ispraviti kada je u pitanju EEG [14].

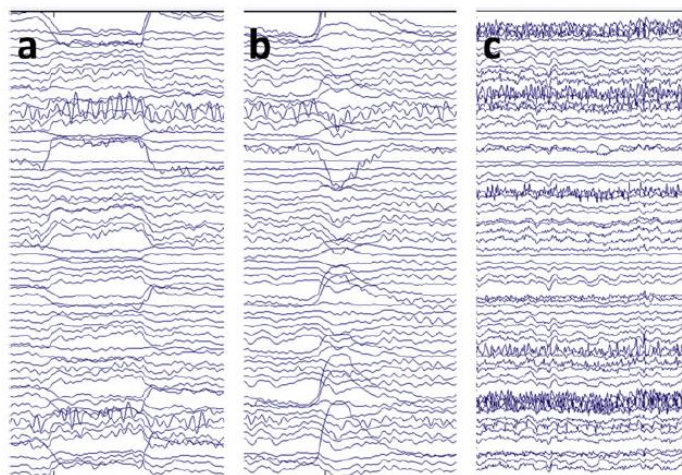


Figura 7: *Primjeri okularnih i mišićnih artefakata: pokret oka (a), treptaj (b) i kontrakcija mišića (c) [24]*

## 4.2 Metode uklanjanja artefakata

Predprocesiranje EEG signala uključuje uklanjanje artefakata koji su objašnjeni u prethodnom odjeljku kako bi se dobili signali koji su spremni za obradu. Prema [16], metode uklanjanja se mogu svrstati u jednu od dvije vrste: grupa metoda koja ispravlja jedan kanal nezavisno od drugih; i grupa metoda koja procesira sve kanale skupa. Prva grupa uključuje metode koje koriste različite tehnike, poput linearne regresije, filtriranja i empirijske dekompozicije signala [16].

### 4.2.1. FILTERI ZA PROCESIRANJE EEG SIGNALA

U ovom odjeljku ćemo se bazirati na filtere za obradu EEG signala, poput *notch* filtera, *band-pass* filtera, *median* filtera i drugih metoda za filtriranje. Filteri koji se koriste za uklanjanje artefakata grade statističku mašinu čiji su parametri procijenjeni sa određenim ciljevima, pravilima učenja, strukturama modela, kao i podacima [16]. Postoji nekoliko

vrsta filtera za EEG signale, a mi ćemo se u ovom odjeljku osvrnuti na njih nekoliko, uključujući četiri vrste pass filtera.

### Pass filteri (low-pass, high-pass, band-pass i band-stop/notch)

Prema tome koji filteri ostaju ili se uklanjaju, postoje četiri tipa pass filtera:

- low-pass filter,
- high-pass filter,
- band-pass filter
- band-stop (notch) filter [24].

Za **low-pass filter**, signali sa niskim frekvencijama ispod određene vrijednosti se zadržavaju, dok se frekvencije veće od neke zadate vrijednosti uklanjaju ili prilagođavaju. Za **high-pass filter**, samo frekvencije sa frekvencijama veće od neke vrijednosti se zadržavaju, dok se samo one sa niskim frekvencijama ispod određene vrijednosti uklanjaju/mijenjaju [24].

Kada je u pitanju **band-pass filter**, on u suštini objedinjuje funkciju low-pass i high-pass filtera, budući da se za ovaj filter postave donja i gornja granica, te se frekvencije unutar tih vrijednosti zadržavaju, dok se one koje su niže od donje granice i veće od zadate gornje granice uklanjaju.

**Band-stop (notch) filter** uklanja signale između neke donje i gornje granice, dok se signali ispod donje ili iznad gornje granice zadržavaju [24]. Ovo je filter koji može zaustaviti signale određenih frekvencija da budu filtrirani [14]. Nakon snimanja EEG signala, jedan od najočitijih šumova koji će biti prisutan u signalu je frekvencija signala iz elektroenergetske mreže. Notch filter na vrijednosti 60 Hz/50 Hz se koristi da se filtrira ovaj šum sa minimalnim ometanjem ostatka signala [14].

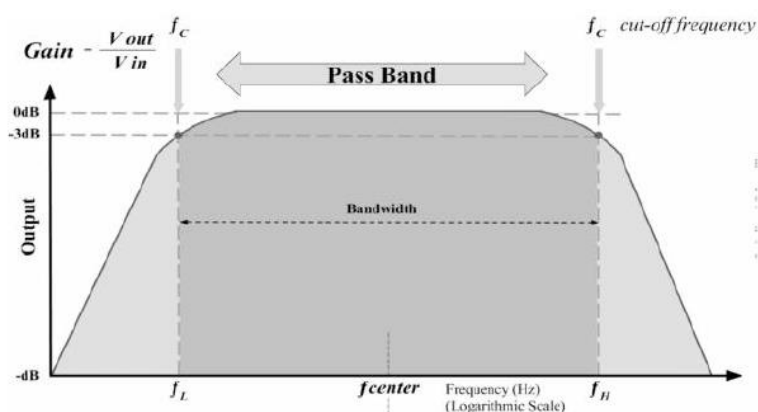


Figura 8: *Frekvencijske karakteristike band-pass filtera* [14]




Figura 9: Frekvencijske karakteristike tri pass filtera: low.-pass filter koji zadržava frekvencije ispod neke date vrijednosti (1), high-pass filter koji zadržava frekvencije iznad neke date vrijednosti (2), i band-stop (notch) filter koji zadržava vrijednosti van nekih datih granica (3) [24]




Figura 10: Karakteristika (band-stop) notch filtera [14]

### Adaptivni filteri

Adaptivni filteri se koriste za uklanjanje šumova iz EEG signala. Ovaj filter za uklanjanje šumova zahtijeva referentni signal [23]. U svojoj suštini, adaptivni filteri ne podrazumijevaju korelaciju između signala i artefakata [16]. Ovi filteri modeliraju način na koji artefakti kontaminiraju EEG signal prilagođavajući tzv. Težine filtera pravilu učenja koje formira algoritam za optimizaciju [23]. Npr., neka je  $x[n]$  posmatrani EEG signal sa nepoznatim čistim EEG signalom  $y[n]$ , dok je  $z[n]$  signal artefakta [16]. Ovo se matematički prikazuje kao:

$$x[n] = y[n] + z[n]$$

Ako je poznata referenca na artefakt  $r[n]$ , adaptivni filter prilagođava svoje tzv. težine (engl. *weights*)  $w$  da bi se minimizirala greška između  $x[n]$  i  $w^T r[n]$ . Kako  $r[n]$  nije u vezi sa  $y[n]$ , idealne težine bi učinile  $w^T r[n]$  što bliže  $z[n]$ . Onda bi razlika  $\{x[n] - w^T r[n]\}$  bila bliže  $y[n]$ .

Postoji dosta algoritama za prilagođavanje ovih težina, ali to izlazi van okvira ovog rada.



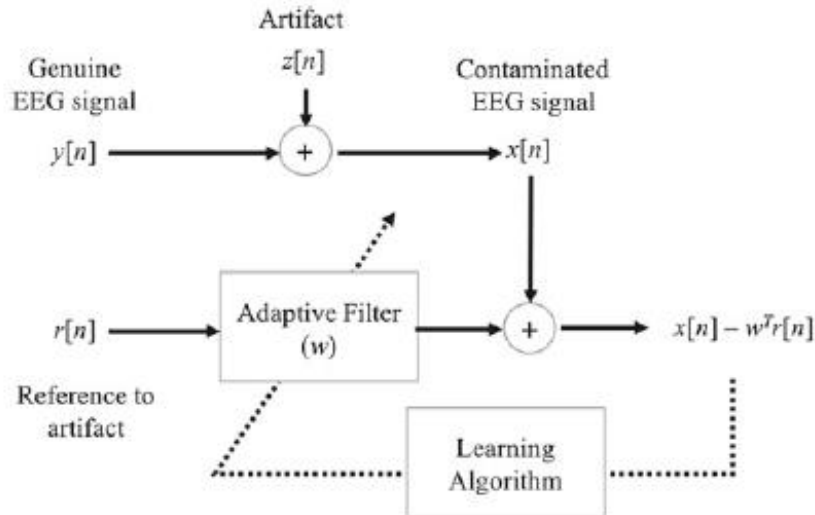


Figura 11: Shema za uklanjanje EEG šumova koristeći adaptivno filtriranje [16]

### Wienerov filter

Kao što smo već spomenuli, najpoznatiji adaptivni filter je Wiener filter. Wiener filter je linearni vremenski invarijantan (LTI) filter koji minimizira srednju kvadratnu grešku između traženog odgovora i izlaza filtera [16]. Optimalne težine filtera se procjenjuju na osnovu Wiener-Hopfove jednačine.

#### 4.2.2. SLIJEPO UKLANJANJE IZVORA (ENGL. BLIND SOURCE SEPARATION (BSS))

Slijepo uklanjanje izvora (*engl. BSS - blind source separation*) je metoda koja se najčešće koristi za uklanjanje artefakata kada su informacije o njima ograničene [16].

Osnovne BSS metode pretpostavljaju linearan model u kojem se posmatrani višekanalni EEG signali gledaju kao linearna kombinacija nepoznatih izvora sa malo znanja o njima. Optimalna procjena izvora sa matricom kombiniranja se postiže pretpostavkama na izvorima tako da su izvori međusobno nezavisni ili nepovezani [16].

Na primjer, ako je  $x$  neki posmatrani vektor EEG signala, koji je kombinacija nepoznatog izvornog vektora  $s$  sa kombinacijskom matricom  $A$ , dok  $n$  predstavlja neki šum, to se predstavlja kao:

$$x = As + n$$

BSS metode procjenjuju  $A$  tako da se izvori u  $s$  predstavljaju što više nezavisnim. Kada je  $A$  procijenjeno, inverzna matrica  $A^{-1}$  se koristi da bi se našli izvori predstavljeni kao:

$$s = Wx$$

Ovi procijenjeni izvori se kasnije ispituju empirijski (npr. vizualno) ili automatski (koristeći algoritme za automatsko biranje izvora) kako bi se otkrili izvori koji potiču od spomenutih artefakata [16].

Ipak, važno ograničenje BSS metode je to što zahtijeva višekanalne EEG podatke i uvijek postoji mogućnost da uklonjeni izvori možda također nose informacije o moždanoj aktivnosti [16].

## 5. EKSTRAKCIJA ZNAČAJKI I ANALIZA SIGNALA

### 5.1 Analiza signala

Cilj analize signala u BCI sistemu jeste maksimizacija omjera signala i šuma (*engl. Signal-to-noise ratio, SNR*) EEG-a ili značajki jedinica koje prenose poruke i naredbe korisnika. Da bi se postigao ovaj cilj, bitno je uzeti u obzir glavne izvore šuma. Šum ima neuralne izvore (npr. EEG značajke koje se ne koriste za komunikaciju) i ne-neuralne izvore (npr. pokreti očiju, EMG, 60-Hz linija šuma). Problemi detekcije i razlikovanja šuma su najveći kada su karakteristike šuma slične u frekvenciji, vremenu ili amplitudi s onima željenog signala. Od značaja je snimiti dovoljno informacija (npr. topografske i spektralne distribucije) kako bi se omogućilo razlikovanje između signala i šuma. Na neneuralni šum kao što je EMG posebno je potrebno obratiti pažnju, budući da korisnikova kontrola nad njim može lako izgledati kao stvarna EEG kontrola.

Važno je i napraviti jasnu razliku između različitih neuralnih značajki. Vizualni ritam je izvor šuma kada je ritam značajka koja se koristi za komunikaciju. Iako odgovarajuće metode temporalne i prostorne filtracije mogu pomoći u takvim razlikama, signali iz različitih izvora mogu imati slične frekvencijske spektre i slične prostorne distribucije. Ako se ne-neuralni i neuralni šum može detektirati online, u tijeku rada BCI-a, njegov utjecaj na rad može se znatno smanjiti ili eliminirati. Na primjer, u BCI-u pokretanom sporim kortikalnim potencijalima, ulaz kontaminiran pokretima očiju može se odbaciti. Ovaj pristup također može potaknuti korisnika da smanji proizvodnju takvog šuma. Postoje mnoge opcije za obradu signala u BCI dizajnu. Konačno, trebaju se usporediti u online eksperimentima koji mjere brzinu i točnost.

Estimacija parametara autoregresivnog (*AR*) modela korisna je metoda za opisivanje EEG aktivnosti i može biti korisna za BCI primjene. AR model obično pretpostavlja Gaussov proces. Budući da vrlo mali ne-Gaussovski ostaci mogu značajno utjecati na estimaciju AR parametara, ovi ostaci trebaju biti procijenjeni. Kada je prisutno dodatno kontaminiranje odstupanjima, generalizirana robustna procjena maksimalne izvedbe (*engl. generalized maximum - GM*) može biti vrijedna. Ova metoda temelji se na modificiranom Kalmanovom filtru. GM metode daju rezultate slične tipičnoj AR procjeni za Gaussove podatke, ali su bolje za ne-Gaussovske podatke. Bayesove algoritme, koji mogu procijeniti sigurnost da je sistemova interpretacija korisnikove namjere ispravna, također mogu biti korisni. Mogu zaustaviti komunikaciju kada ta sigurnost padne ispod određene razine, čime se smanjuju pogreške u BCI izvedbi.

Metode procesiranja signala su itekako od značaja u dizajnu BCI sistema, no i one posjeduju određene limite. Iako mogu poboljšati omjer signala i šuma, ne mogu izravno pozabaviti utjecajem promjena u samom signalu. Faktori poput motivacije, namjere, frustracije, umora i učenja utiču na ulazne značajke koje korisnik pruža. Stoga se razvoj BCI-a oslanja na prikladno upravljanje prilagodljivim interakcijama između sistema i korisnika, kao i na odabir prikladnih metoda obrade signala [2].



## 5.2 Ekstrakcija značajki

Potrebna je temeljita analiza efikasnosti svake značajke algoritma da bi se osigurali najbolji rezultati [13]. EEG ekstrakcija značajki predstavlja ključnu etapu koja direktno utiče na postupak klasifikacije. Poznate su mnoge studije koje opisuju različite algoritme za ekstrakciju značajki, te će ovdje biti obrađene najpoznatije:

- Wavelet transformacija (WT),
- Analiza glavnih komponenti,
- Hjorthovi parametri,
- Analiza nezavisnih komponenti,
- Statističke karakteristike
- Fast Fourier Transform (FFT) i
- Event-Related Potential (ERP).

### 5.2.1 FAST FOURIER TRANSFORMACIJA (FFT)

**Fast Fourier Transformacija (FFT)** je algoritam koji ima najbrže izvršenje, te je vrlo koristan za obradu stacionarnih signala. Međutim, zbog ograničene frekvencijske rezolucije i visokog gubitka spektralnih informacija, algoritam je loš izbor za određivanje stvarne frekvencije signala [17]. Algoritam ima poteškoća s nestacionarnim signalima poput EEG-a jer ne može razlikovati lokalizirane "špiceve" (*engl. spikes*) i komplekse koji su česti u EEG signalima, posebno u eliptičnim napadima. Nadalje, algoritam je osjetljiv na velike količine šuma i nedostaje mu kraća trajanja zapisa podataka [18].

Karakteristike stečenog EEG signala koji će se analizirati izračunavaju se procjenom spektralne gustoće snage (*engl. power spectral density* - PSD) kako bi se selektivno predstavili uzorci EEG signala. Međutim, četiri frekvencijska pojasa sadrže glavne karakteristične valne oblike spektra EEG-a. PSD se računa Fourierovom transformacijom procijenjene sekvence autokorelacije koja se dobiva neparametarskim metodama. Jedna od tih metoda je Welchova metoda. Sekvenca podataka primjenjuje se na prozorsko modeliranje podataka, što rezultira modificiranim periodogramima. Informacijska sekvencija  $x_i(n)$  izražena je sa:

$$x_i(n) = x(n + iD), n = 0, 1, 2, \dots, M - 1 \\ \text{while } i = 0, 1, 2, \dots, L - 1;$$

gdje je  $iD$  početna tačka  $i$ -te sekvence, dok  $L$  dužine  $2M$  predstavlja segmente podataka koji se formiraju. Rezultujući izlaz periodograma daje:

$$P_{xx}^{\approx(i)}(f) = \frac{1}{MU} \left| \sum_{n=0}^{M-1} x_i(n) w(n) e^{-j2\pi f n} \right|^2$$

$U$  doprinosi faktoru normalizacije snage i određuje se po sljedećoj formuli:

$$U = \frac{1}{M} \sum_{n=0}^{M-1} w^2(n)$$

gdje je  $w(n)$  tzv. window funkcija [12]. Za Welchov spektar snage dobijamo:

$$P_{xx}^w = \frac{1}{L} \sum_{i=0}^{L-1} P_{xx}^{\approx(i)}(f)$$

## 5.2.2 HJORTHOMI PARAMETRI

**Hjorthovi parametri** općenito se temelje na tri načela EEG signala, ali ih se može ekstrapolirati kako bi se zadovoljile specifične potrebe. Općenito se koristi za opisivanje EEG karakteristika poput aktivnosti, pokretljivosti, i složenosti. Nedostatak ove tehnike izdvajanja značajki je njena osjetljivost na šum, pa se tehnike uklanjanja šuma moraju temeljito provesti prije primjene ove tehnike [13].

## 5.2.3 METODA EKSTRAKCIJE SNAGE POJASA

**Metoda ekstrakcije snage pojasa** može se koristiti za dekompoziciju originalnog EEG signala u različite frekvencijske pojaseve poput delta (0,5-4 Hz), teta (4-8 Hz), alfa (8-12 Hz), beta (12-30 Hz), i gama (30-100 Hz). Metoda je računalno lagana, ali nije informativna kao druge metode ekstrakcije frekvencija. Spektralna gustoća snage (**PSD**) idealna je za prikazivanje snage energije u EEG signalu kao funkcije frekvencije. Tehnika koristi dvije metode: Welchovu metodu i Burgovu metodu. Tačnost klasifikatora u potpunosti zavisi od kombinacije kanala i vrste korištene metode PSD-a [13].

## 5.2.4 WAVELET TRANSFORMACIJA

**Wavelet transformacija** izvrsna je u opisivanju svojstava signala unutar određenog frekvencijskog domena i lokaliziranog vremenskog domena. Omogućuje analizu nekonzistentnih obrazaca podataka upotrebom varijabilnih prozora, s širokim prozorima dodijeljenim nižim frekvencijama i uskim prozorima dodijeljenim višim frekvencijama. S druge strane, algoritam ima visoke računalne i memorijske zahtjeve [17] i zahtijeva ispravan odabir matične talasne funkcije [18].

Metoda Wavelet transformacije (WT) igra važnu ulogu u području prepoznavanja i dijagnostike: vrši kompresiju vremenski promjenjivog biomedicinskog signala, koji sadrži mnogo podataka, u nekoliko malih parametara koji predstavljaju signal [19].

Kako je EEG signal nestacionaran, najprikladniji način za izdvajanje značajki iz sirovih podataka je korištenje metoda u domeni vremena i frekvencije poput wavelet transformacije (WT), koja je tehnika spektralne procjene u kojoj se bilo koja opća funkcija može izraziti kao beskonačni niz waveleta. Budući da WT omogućuje upotrebu varijabilnih veličina prozora, pruža fleksibilniji način reprezentacije signala u domeni vremena i frekvencije. Kako bi se postigla finija rezolucija niskih frekvencija, koriste se WT prozori dužeg vremena; za visokofrekventne informacije, koriste se kratki vremenski prozori [20].

Osim toga, WT uključuje samo višestruku strukturu, a ne jednostruku skalu. Ova metoda samo je nastavak ortodoksne Fourierove transformacije [21]. Nadalje, namijenjena je rješavanju problema nestacionarnih signala poput EEG-a. U WT metodi, originalni EEG signal predstavljen je sigurnim i jednostavnim gradivnim blokovima poznatim kao waveleti. Matični wavelet stvara ove wavelete kao dio izvedenih funkcija putem operacija translacije i dilatacije, tj. (pomaka) i (stiskanja i rastezanja) duž vremenske osi, redom. Postoje dvije kategorije za WT; prva je kontinualna dok je druga diskretna [13].

#### Kontinualna (CWT):

$$CWT(a, b) = \int_{-\infty}^{+\infty} x(t)\psi_{a,b}(t)dt$$

gdje je  $x(t)$  neprocesuirani EEG,  $a$  dilatacija,  $b$  faktor translacije.  $\psi_{a,b}(t)$  predstavlja kompleksno konjugovani broj, koji se računa po formuli:

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}}\psi\left(\frac{t-b}{a}\right)$$

gdje  $(t)$  predstavlja *wavelet*.

Međutim, glavna slabost ovog pristupa jeste što se skalarni parametar  $a$  i translacijski parametar  $b$  CWT kontinualno mijenjaju. Stoga će koeficijenti waveleta za sve dostupne skale nakon računanja zahtijevati puno truda i rezultirati u velikom broju neiskorištenih informacija.

#### Diskretna (DWT):

Kako bi se adresirala slabost CWT-a, definirana je diskretna wavelet transformacija (DWT) na osnovi višeskalne reprezentacije značajki. Svaka razmatrana skala predstavlja jedinstvenu debljinu EEG signala. Multirezolucijska dekompozicija sirovih EEG podataka  $x(n)$  prikazana je na **slici 3**. Svaki korak sadrži dva digitalna filtra,  $g(n)$  i  $h(n)$ , te dva downsampla za faktor 2. Diskretni matični wavelet  $g(n)$  prirode je visokopropusni, dok je  $h(n)$  po prirodi niskopropusni.

Kao što je prikazano na **slici 3**, svaki izlaz stupnja pruža detalje signala  $D$  i aproksimaciju signala  $A$ , pri čemu posljednji postaje ulaz za sljedeći korak. Broj razina na koje se wavelet dekomponira odabire se ovisno o komponenti EEG podataka s dominantnom frekvencijom. [12]

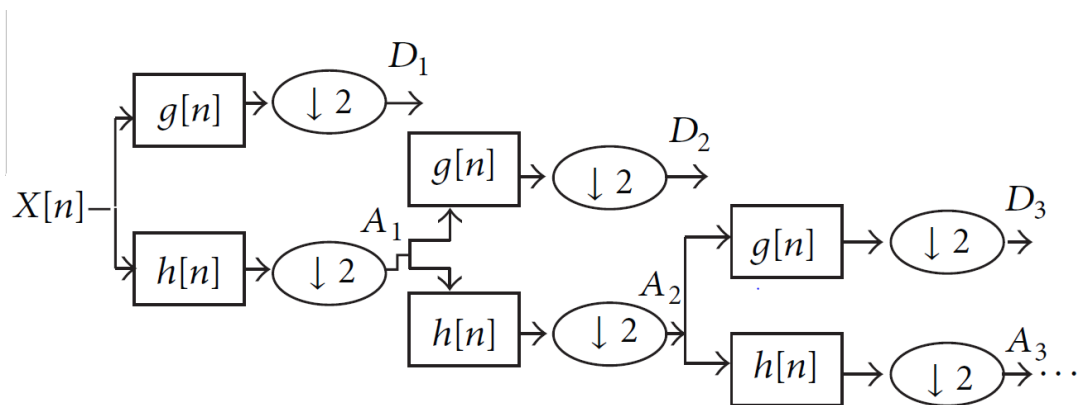


Figura 12: Implementacija dekompozicije DWT-e

Veza između WT-a i filtra  $h$ , odnosno, niskopropusnog filtra, može se prikazati na sljedeći način:

$$H(z) H(z^{-1}) + H(-z) H(-z^{-1}) = 1$$

Gdje  $H(z)$  predstavlja  $z$ -transformaciju filtra  $h$ , a komplementarna  $z$ -transformacija visokopropusnog filtra je izražena:

$$G(z) = z H(-z^{-1})$$

Preciznim opisom značajki segmenta signala unutar određenog frekvencijskog domena i lokaliziranih svojstava vremenskog domena, postoji mnogo prednosti koje nadmašuju visoke računalne i memorijske zahtjeve konvencionalne implementacije DWT-a temeljene na konvoluciji.

Ime metode	Prednosti	Nedostaci	Metoda analize	Prikladnost
Fast Fourier Transform	(i) Dobar alat za obradu stacionarnih signala (ii) Prikladniji je za uske signale, poput sinusoida (iii) Ima poboljšanu brzinu u poređenju s gotovo svim drugim dostupnim metodama u aplikacijama u stvarnom vremenu	(i) Slabosti u analiziranju nestacionarnih signala poput EEG-a. (ii) Nema dobru spektralnu procjenu i ne može se koristiti za analizu kratkih EEG signala. (iii) FFT ne može otkriti lokalizovane šiljke i komplekse koji su tipični za epileptične napade u EEG signalima. (iv) FFT je osjetljiv na veliku buku i nema podatke sa kraćom dužinom trajanja.	Frekvencijski domen	Stacionarni signali
Wavelet transformacija	(i) Ima promjenljivu veličinu prozora, širokog kod niskih frekvencija i uskog kod visokih frekvencija (iii) Bolje je prilagođen analizi naglih i prolaznih promjena	Zahtijeva biranje odgovarajućeg osnovnog talasa	I vremenski i frekvencijski domen	Kratkotrajni i stacionarni signali

	signala (iii) Bolje je postavljen za analizu nepravilnih uzoraka podataka, tj. impulsa koji postoje u različitim vremenskim trenucima			
Eigenvector	Daje odgovarajuću rezoluciju za evaluaciju sinusoida iz podataka.	Najmanja svojstvena vrijednost može generisati lažne nule kada se koristi Pisarenkov metod.	Frekvencijski domen	Signali 'poklopljeni' šumovima
Distribucija vrijeme-frekvencija	(i) Pruža mogućnost pregleda velikih neprekidnih segmenata EEG signala. (ii) TFD analizira samo čisti signal za dobre rezultate.	(i) Metode vremensko-frekvencijske analize su usmjerene na obradu koncepta stacionarnosti; kao rezultat, proces prozoriranja je potreban u modulu predprocesiranja. (ii) Prilično je spor (zbog računanja gradijenta uzlaznog uspona). (iii) Izdvojene karakteristike mogu biti međusobno zavisne.	I vremenski i frekvencijski domen	Stacionarni signali
Autoregresivnost	(i) AR ograničava gubitak spektralnih problema i pruža poboljšanu rezoluciju frekvencije. (ii) Pruža dobru rezoluciju frekvencije.  (iii) Spektralna analiza bazirana na AR modelu je posebno povoljna kada se analiziraju kratki segmenti podataka, budući da je frekvencijska rezolucija analitički izvedenog AR spektra beskonačna i ne zavisi od dužine analiziranih podataka.	(i) Izbor reda modela u spektralnoj procjeni AR-a je težak.  (ii) AR metod će pružiti lošu spektralnu procjenu ukoliko procijenjeni model nije odgovarajući, i ukoliko su redovi modela netačno izabrani.  (iii) Podložan je teškim pristrasnostima čak i velikoj varijabilnosti.	Frekvencijski domen	Signali sa oštrim spektralnim karakteristikama

Tabela 2: Prednosti i nedostaci svih metoda za EEG analizu

## 6. KLASIFIKACIJA I ALGORITMI MAŠINSKOG UČENJA

U interfejsu mozak-računar (BCI) koje koristi EEG (elektroencefalografija) podatke, klasifikacija podrazumijeva proces kategoriziranja uzoraka moždane aktivnosti u različite klase ili kategorije. Ova klasifikacija se često provodi pomoću algoritama mašinskog učenja, koji analiziraju EEG signale i uče povezivati ih s određenim mentalnim stanjima, naredbama ili namjerama.

Uobičajeni algoritmi mašinskog učenja korišteni za klasifikaciju u BCI sistemima su:

1. Potporni vektori (Support Vector Machines - SVM)
2. Vještačke neuronske mreže (ANN)
3. k-najbližih susjeda (k-NN)
4. Linearna diskriminativna analiza (LDA)
5. Konvolucijske neuralne mreže (CNN) za pristupe dubokog učenja

Ovi algoritmi se treniraju na označenim EEG podacima, gdje je svaki uzorak povezan s poznatim mentalnim stanjem ili akcijom, omogućavajući algoritmima da nauče obrasce koji odgovaraju različitim kognitivnim stanjima ili namjerama. Nakon obuke, klasifikatori mogu predvidjeti klasu novih EEG uzoraka u stvarnom vremenu, omogućavajući korisnicima upravljanje uređajima ili interfejsima putem moždane aktivnosti [4, 5].

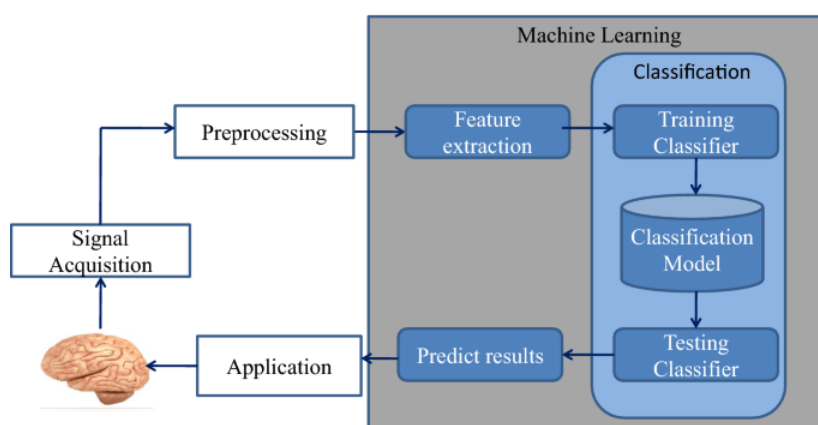


Figura 13: Veza BCI-ja i mašinskog učenja

*Reinforcement learning* gdje agent uči kako da donosi zaključke ili pokreće akcije da maksimizira kumulativnu nagradu, najviše se koristi za neurofeedback. Duboke neuralne mreže – procesuiraju kompleksne moždane signale, te imaju ključnu ulogu u dekodiranju moždanih talasa i njihovom prevođenju u prikladne naredbe za uređaje. Konvolucijske neuralne mreže koriste se za *image-based neurofeedback* [3]. Za više informacija pogledati [4, 9].

## 7. PRIMJENA BCI SISTEMA

BCI alati imaju potencijalnu primjenu koja se prostire na barem pet različitih područja: verbalna komunikacija, svakodnevne aktivnosti, kontrola okoliša, pokretljivost, i vježbanje. U biranju ovih područja, potrebe i prioriteti potencijalnog korisnika bi trebale biti primarni interes. Razvojni inženjeri koji rade na primjeni BCI-a moraju se čuvati tendencije da pristupaju parametrima ovih alata i njegovim aplikacijama kao apstraktnoj dizajnerskoj vježbi. BCI i njegove primjene trebaju biti optimizirane za svakog korisnika ili korisničku grupu. U isto vrijeme, proces optimizacije treba biti što više standardiziran i objektivan. Za svakog korisnika, BCI i njegove primjene trebali bi biti ugrađeni u program ponašanja sa dobro definisanim ciljevima. Razvoj BCI-ja trebalo bi da uključuje ne samo jednostavne tehničke i elektrofiziološke principe, već i dobro definisane principe učenja [2].

Glavne ciljne skupine za primjene BCI aplikacija podijeljene su u tri klase. Prva grupa uključuje pacijente u potpunom zaključanom stanju (*Complete Locked-In State* - CLIS) koji su izgubili svu motoričku kontrolu. Druga grupa obuhvata pacijente u stanju zaključanosti (*Locked-In State* - LIS) koji su gotovo potpuno paralizirani, ali imaju rezidualno dobrovoljno kretanje, poput kretanja očiju, treptanja ili trzanja usana. Treća grupa potencijalnih korisnika BCI-a uključuje zdrave ljude i one s značajnom neuromuskularnom kontrolom, posebno govornom i/ili kontrolom ruku. BCI malo nudi trećoj grupi jer iste informacije mogu puno brže i lakše poslati putem drugih interfejsa, umjesto putem BCI-a. BCI također primjenu pronalazi i kod osoba oboljelih od raznih neuroloških poremećaja, kao što su šizofrenija ili depresija. [1]

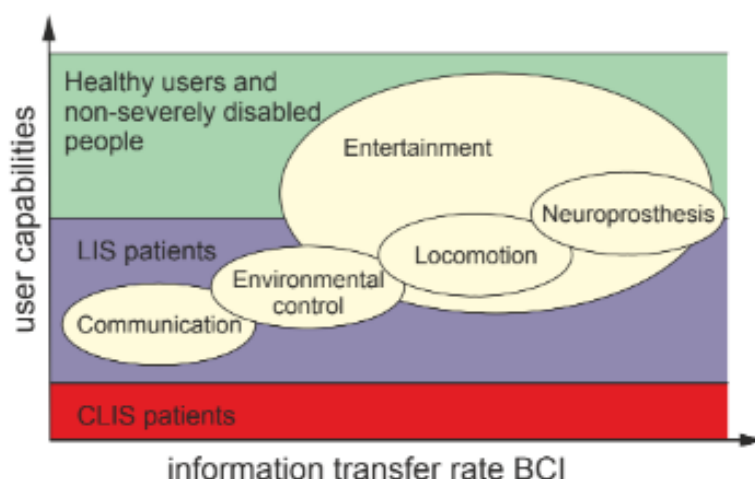


Figura 14: Veza između područja primjene BCI sistema, brzina prijenosa informacija i korisničkih sposobnosti. Horizontalna osa: brzina prijenosa informacija sa kojom bi se primjena mogla kontrolirati. Vertikalna osa: stepen sposobnosti [1].

Trenutno nije jasno hoće li tehnologija BCI-a ikada nadmašiti druge uspostavljene tehnologije koje uključuju uređaje temeljene na oku ili mišićima. Trenutno su potonji uređaji obično lakši za korištenje i nude bolji omjer koristi i troškova [1].

## 7.1 BCI u zabavne svrhe

Aplikacije BCI-a orijentirane na zabavu obično su imale niži prioritet u ovom području. Do sada, istraživanja o tehnologiji BCI-a obično su se usredotočila na asistivne aplikacije, poput uređaja za pisanje, upravljanja invalidskim kolicima ili neuroproteza, umjesto na aplikacije s zabavnim svrhama. Međutim, interes za zabavne aplikacije pojavio se posljednjih godina zbog značajnog napretka u ovoj tehnologiji.

Poboljšanja u njezinoj izvedbi otvorila su put za proširenje upotrebe BCI-a na ljude bez invaliditeta. BCI implemetiran u sklopu igara stvara novitet koji može pretvoriti videoigre u još izazovnija i atraktivnija iskustva. Osim toga, BCI može pružiti način pristupa znanju o korisnikovim iskustvima, čime se igre poboljšavaju putem informacija iz moždane aktivnosti. BCI može izvijestiti kada je igraču dosadno, kada je anksiozan ili frustriran s ciljem korištenja tog znanja za dizajniranje budućih igara [1].




Figura 15: *Igra Pacman. Igrač mora da se kreće kroz labirint da dođe do izlaza u desnom zidu. Najkraći put označen je sivom bojom, ali igrač može ići i kroz ostatak labirinta da dobije dodatne bodove [1].*

## 7.1 Izazovi u daljem razvoju BCI

Danas postoji veliki broj vrlo različitih aplikacija BCI-a, poput procesora riječi, prilagođenih web preglednika, upravljanja invalidskim kolicima ili neuroprotezama pomoću mozga te igara, među ostalima. Međutim, većina aplikacija dizajnirana je isključivo u svrhu obuke ili demonstracije. Uprkos najnovijim značajnim naprecima u tehnologiji BCI-a, još uvijek postoji mnogo izazova pri primjeni BCI upravljanja za zadatke u stvarnom svijetu:

1. stopa prijenosa informacija koju pružaju BCI-i je preniska za sposobnosti korisnika, što otežava prirodni interaktivni razgovor, čak i za iskusne subjekte i dobro podešene BCI sisteme;
2. visoka stopa pogrešaka dodatno komplicira interakciju;
3. BCI sistemi ne mogu se koristiti autonomno od strane osoba s invaliditetom jer zahtijevaju pomoćnike za postavljanje elektroda ili uređaja za primanje signala prije nego što osoba s invaliditetom može komunicirati;
4. korisnik BCI-a može isključiti BCI sistem putem moždane aktivnosti kao ulaza, ali obično ga ne može ponovno uključiti, što se naziva problemom *Midasovog dodira*;
5. rukovanje BCI aplikacijama zahtijeva visoko kognitivno opterećenje koje korisnici obično mogu postići u tihoj laboratorijskoj okolini, ali ne i u stvarnom svijetu.

Uprkos svim tim izazovima, već su poduzeti prvi koraci na putu prema dugoročnoj nezavisnoj kućnoj upotrebi BCI-ja. [1]



## 8. ZAKLJUČAK I DISKUSIJA

Iz svega izloženog, da se primijetiti da BCI sistemi uistinu predstavljaju korak dalje u interakciji čovjeka sa računarom i u razumijevanju rada ljudskog mozga. Kako je i mozak sam po sebi jedan od najistraživanijih organa i kako naučnici već stoljećima pokušavaju doprijeti do svih njegovih misterija, ne treba sumnjati da će i BCI sistemi igrati veliku ulogu u daljem napretku naučnih disciplina poput neuronauke, ali i medicinskih polja poput neurologije.

Ovaj rad je detaljno obradio procesiranje EEG signala kao važan dio BCI sistema te su date osnovne informacije o moždanim signalima koje BCI obrađuje. Kao što smo već vidjeli, EEG tehnologija je izdržala test vremena zbog svoje efikasnosti, i zbog toga je vrlo izvjesno je da će EEG tehnologija i dalje ostati najrasprostranjeniji način snimanja moždanih signala kada je pitanju BCI, najviše zbog neinvazivnosti metode, ali i visoke stope njene pouzdanosti. Pored toga, EEG se pokazala kao poprilično pristupačna metoda i može se reći da će ova tehnologija zadržati svoje mjesto čak i uprkos potencijalnoj pojavi novih metoda za snimanje moždanih talasa.

Dekodiranje električnih signala iz mozga i dalje ostaje srž bilo kojeg BCI sistema i nevjerovatno je da danas se danas, koristeći ove signale, misli, namjere i emocije mogu prevesti u izvodive komande. Koristeći ovaj interfejs čovjeka i mašine, inovatori i istraživači su otvorili veliki broj mogućnosti u različitim poljima, od zdravstva i asistivnih tehnologija do zabave o kojoj smo govorili u prethodnom odjeljku.

Sigurno je da razvoj BCI sistema ima svijetlu budućnost sa mnogo naučnika koji svakodnevno rade na daljem razvoju ove tehnologije. Sistemi koje ovi naučnici istražuju koriste različite moždane signale, druge metode snimanja i pristupe procesiranju signala. Ono na čemu će se sigurno raditi je poboljšanje preciznosti i brzine komunikacije između mozga i računara, što će za rezultat imati bolje vrijeme odziva i bolje rezultate korištenja BCI sistema.

Najvažnija primjena BCI sistema leži u sferi medicine. Ova tehnologija ima transformativne mogućnosti u pogledu rehabilitacije pacijenata nakon moždanog udara, kontrole pomagala za osobe sa invaliditetom te unapređenja dijagnostike neuroloških oboljenja. Posebno je važno istaći koliki potencijal ovi sistemi imaju za osobe sa invaliditetom jer uz njihovu upotrebu, osobe koje su izgubile sposobnost komunikacije imaju mogućnost da pišu poruke ili kontrolišu protetičke udove. Za ove ljude, BCI je nada i prilika za budućnost. Ono što predstavlja prepreku kada je u pitanju BCI su šumovi o kojima smo govorili u odjeljcima o procesiranju, kao i ograničena prostorna rezolucija.

Konačno, BCI sistemi predstavljaju nevjerovatno dostignuće u pogledu tehnologije i nema sumnje da će istraživački potencijal vezan za ovu tehnologiju samo rasti u budućnosti, čime će istraživači imati priliku da rade na poboljšanju kvalitete života kroz različite primjene ovih sistema. Dalji razvoj relevantnih naučnih i tehnoloških disciplina i inovacija bit će od velike važnosti za postizanje punog potencijala BCI sistema u godinama koje dolaze.

## 9. REFERENCE

- [1] L. F. Nicolas-Alonso & J. Gomez-Gil, "Brain Computer Interfaces, a Review," *Sensors*, vol. 12, no. 2, pp. 1211–1279, Jan. 2012, doi: <https://doi.org/10.3390/s120201211>.
- [2] J. R. Wolpaw *et al.*, "Brain-computer interface technology: a review of the first international meeting," *IEEE Transactions on Rehabilitation Engineering*, vol. 8, no. 2, pp. 164–173, Jun. 2000, doi: <https://doi.org/10.1109/tre.2000.847807>.
- [3] D. Suriyamurthi, "Role of Machine Learning Algorithms in Brain-Computer Interface: A Comprehensive Review Role of Machine Learning Algorithms in Brain- Computer Interface: A Comprehensive Review," Dec. 2023.
- [4] Pawan & R. Dhiman, "Machine learning techniques for electroencephalogram-based brain-computer interface: A systematic literature review," *Measurement: Sensors*, vol. 28, p. 100823, Aug. 2023, doi: <https://doi.org/10.1016/j.measen.2023.100823>.
- [5] "Machine Learning for BCI," *NeurotechEDU*.  
<https://learn.neurotechedu.com/machinelearning/> (accessed Mar. 19, 2024).
- [6] G. Buzsáki, C. A. Anastassiou, & C. Koch, "The origin of extracellular fields and currents — EEG, ECoG, LFP and spikes," *Nature Reviews Neuroscience*, vol. 13, no. 6, pp. 407–420, May 2012, doi: <https://doi.org/10.1038/nrn3241>.
- [7] M. Teplan, "Fundamentals of EEG Measurement," *Measurement Science Review*, vol. 2, no. 2, Jan. 2002, Dostupno:  
<http://www.edumed.org.br/cursos/neurociencia/MethodsEEGMeasurement.pdf>
- [8] S. Siuly, Y. Li, & Y. Zhang, *EEG Signal Analysis and Classification*. Springer International Publishing, 2016. doi: <https://doi.org/10.1007/978-3-319-47653-7>.
- [9] S. Paszkiel, *Analysis and Classification of EEG Signals for Brain-Computer Interfaces*. Springer International Publishing, 2020. doi: <https://doi.org/10.1007/978-3-030-30581-9>.
- [10] S. Nagel, "Towards a home-use BCI: fast asynchronous control and robust non-control state detection," Doktorska disertacija, der Mathematisch-Naturwissenschaftlichen Fakultät der Eberhard Karls Universität Tübingen, 2019. Pristupljeno: Mar. 19, 2024. [Online]. Dostupno:  
[https://www.researchgate.net/publication/338423585\\_Towards\\_a\\_home-use\\_BCI\\_fast\\_asynchronous\\_control\\_and\\_robust\\_non-control\\_state\\_detection](https://www.researchgate.net/publication/338423585_Towards_a_home-use_BCI_fast_asynchronous_control_and_robust_non-control_state_detection)
- [11] "Intracranial Monitoring for Epilepsy," *www.hopkinsmedicine.org*, Aug. 08, 2021. <https://www.hopkinsmedicine.org/health/conditions-and-diseases/epilepsy/intracranial-monitoring-forepilepsy#:~:text=Intracranial%20monitoring%20helps%20doctors%20pinpoint> (pristupljeno Mar. 19, 2024).

- [12] A. S. Al-Fahoum & A. A. Al-Fraihat, "Methods of EEG Signal Features Extraction Using Linear Analysis in Frequency and Time-Frequency Domains," *ISRN Neuroscience*, vol. 2014, pp. 1–7, Feb. 2014, doi: <https://doi.org/10.1155/2014/730218>.
- [13] R. Nagarajan, "Feature Extraction of EEG Signals," 2023.
- [14] Narayan Panigrahi & S. P. Mohanty, *Brain Computer Interface*. CRC Press, 2022.
- [15] N. Elsayed, Z. Saad, & M. Bayoumi, "Brain Computer Interface: EEG Signal Preprocessing Issues and Solutions," *International Journal of Computer Applications*, vol. 169, no. 3, pp. 12–16, Jul. 2017, doi: <https://doi.org/10.5120/ijca2017914621>.
- [16] S.-P. Kim, *Computational EEG Analysis: Methods and Applications*. Singapore: Springer Singapore, 2018, pp. 15–28.
- [17] E. P. Torres, E. A. Torres, M. Hernández-Álvarez, & S. G. Yoo, "EEG-Based BCI Emotion Recognition: A Survey," *Sensors*, vol. 20, no. 18, p. 5083, Sep. 2020, doi: <https://doi.org/10.3390/s20185083>.
- [18] D. Cvetkovic, E. D. Übeyli, & I. Cosic, "Wavelet transform feature extraction from human PPG, ECG, and EEG signal responses to ELF PEMF exposures: A pilot study," *Digital Signal Processing*, vol. 18, no. 5, pp. 861–874, Sep. 2008, doi: <https://doi.org/10.1016/j.dsp.2007.05.009>.
- [19] M. R. N. Kousarrizi, A. A. Ghanbari, M. Teshnehlav, M. A. Shorehdeli, & A. Gharaviri, "Feature Extraction and Classification of EEG Signals Using Wavelet Transform, SVM and Artificial Neural Networks for Brain Computer Interfaces," *2009 International Joint Conference on Bioinformatics, Systems Biology and Intelligent Computing*, 2009, doi: <https://doi.org/10.1109/ijcbs.2009.100>.
- [20] N. Hazarika, J. Z. Chen, A. C. Tsoi, & A. Sergejew, "Classification of EEG Signals Using the Wavelet Transform," *Signal Processing*, vol. 59, no. 1, pp. 61–72, Maj 1997, doi: [https://doi.org/10.1016/s0165-1684\(97\)00038-8](https://doi.org/10.1016/s0165-1684(97)00038-8).
- [21] J. S. Kumar & P. Bhuvaneswari, "Analysis of Electroencephalography (EEG) Signals and Its Categorization–A Study," *Procedia Engineering*, vol. 38, pp. 2525–2536, 2012, doi: <https://doi.org/10.1016/j.proeng.2012.06.298>.
- [22] D. Purves *et al.*, "Types of Eye Movements and Their Functions," *Nih.gov*, 2016. <https://www.ncbi.nlm.nih.gov/books/NBK10991/>
- [23] Saeid Sanei, J. A. Chambers, & J. Wiley, *EEG Signal Processing and Machine Learning*. Hoboken, New Jersey, USA: Wiley, 2022.
- [24] L. Hu and Z. Zhang, *EEG Signal Processing and Feature Extraction*. Springer Nature, 2019.
- [25] J. R. Wolpaw & E. Winter Wolpaw, *Brain-computer Interfaces: Principles and Practice*. New York: Oxford University Press, 2012.

[26] J. Vidal, "Toward Direct Brain-Computer Communication," *Annual Review of Biophysics and Bioengineering*, vol. 2, no. 1, pp. 157–180, Jun. 1973, doi: <https://doi.org/10.1146/annurev.bb.02.060173.001105>.

[27] D. Bansal & R. Mahajan, *EEG-Based Brain-Computer Interfaces*. Academic Press, 2019.